

Entregable de fundamentos de valoración y marco Black

Pedro Estévez García
Juan Cristóbal Olmedo Moreno
Javier Puerta Gómez
Paula Simón Ávila
Carlos Zaragoza Navarro

Mayo 2026

Índice

1. Introducción	3
2. Metodología aplicada	5
2.1. Modelos ML	5
2.2. Desagregación de resultados	5
3. Sistema e infraestructura del modelo	8
4. Resultados y análisis de la estrategia	9
5. Conclusiones	10
6. Anexo	11
6.1. Código	11

1. Introducción

La gestión cuantitativa de activos financieros es un enfoque de inversión que utiliza modelos matemáticos y algoritmos computacionales para gestionar una cartera de activos financieros. Para ello, se deben aplicar criterios estrictamente objetivos basados en el análisis de datos y modelización matemática avanzada [2].

Así, un modelo de gestión cuantitativa puede incluir criterios de selección de activos, modelos de riesgo, optimización de carteras, validaciones por backtesting y sistemas de ejecución sistemática según las reglas definidas. Dado que se trata de una definición amplia, existe una gran variedad de estrategias que se pueden calificar como de gestión cuantitativa. La variedad está, entre otras características, en la elección del subyacente, el tipo de activo financiero, los datos utilizados para tratar de predecir los movimientos del mercado, la metodología matemática para modelizar estos cambios, etc.

Nuestro grupo ha apostado por una estrategia de stockpicking sobre el índice EuroStoxx50, es decir, trata de predecir qué acciones del EuroStoxx50 van a tener un mejor desempeño e invierte en ellas. Desde un punto de vista matemático, la metodología más directa que se puede plantear para tratar de predecir rendimientos es realizar algún tipo de regresión. Sin embargo, consideramos que es más adecuado afrontar el problema como una clasificación binaria: en lugar de preguntarnos cuál será el retorno de una acción en el futuro próximo, nos preguntamos si dicha acción quedará en el top N (o superará la mediana) entre sus peers en términos de rentabilidad.

Por tanto, lo anterior se transforma en un problema supervisado de clasificación binaria con múltiples variables explicativas. En este punto, la primera idea es aplicar un modelo de regresión logística: utilizamos datos históricos para obtener los coeficientes del modelo. Esto nos permitirá no solo clasificar cada activo según la variable objetivo definida anteriormente, sino que también permite el cálculo de unas “probabilidades”: un score que permite ordenar los activos según una estimación de la probabilidad de pertenecer a la clase positiva.

Aunque un modelo de regresión logística es una herramienta con la que nos sentimos cómodos debido a la educación de los integrantes del grupo, nos dimos cuenta de que presenta algunos inconvenientes para este problema en particular. La regresión logística sería una opción restrictiva porque asume una relación lineal entre las variables y los logaritmos de las probabilidades de pertenecer a cada grupo de la clasificación binaria. Esto es relevante en este contexto porque es razonable pensar que la relación entre las variables de mercado generalmente utilizadas y las rentabilidades futuras no sea lineal ni estable. Además, la regresión logística no detecta las relaciones entre las variables de manera automática.

En consecuencia de lo anterior, decidimos implementar un modelo de clasificación no lineal basado en árboles de decisión porque resolvían los principales problemas comentados: contemplan relaciones no lineales entre las variables del modelo y la variable objetivo. Además, los modelos basados en árboles pueden manejar de forma más flexible conjuntos de variables redundantes o relacionadas entre sí, sin exigir una relación lineal e independiente de cada variable con la variable objetivo.

En este contexto, no se pretende que el modelo estime una predicción exacta, sino una señal relativa para ordenar los activos y seleccionar candidatos para la cartera. Una vez decidido el mecanismo para la selección de activos, nos encontramos con la decisión de asignar pesos a cada uno de los activos seleccionados por el modelo. Originalmente, optamos por una distribución equiponderada por simplicidad, mientras experimentábamos con distintos mecanismos de elección de pesos.

Los principales métodos de elección de pesos considerados fueron: según los scores del modelo, según ciertos parámetros macroeconómicos, según las correlaciones entre los activos para minimizar la varianza o mediante simulaciones de Montecarlo para optimizar un parámetro como el sharpe. Descartamos la primera opción porque implicaría darle el doble de peso a las decisiones del modelo, y no estábamos tan cómodos con el ratio de acierto del mismo durante los backtests. La segunda opción también la descartamos porque los datos macroeconómicos que a los que se pueden acceder de manera gratuita son limitados, y los backtests mostraban resultados inferiores a las otras estrategias.

Finalmente, decidimos calcular los pesos asignados a los activos mediante simulaciones de Montecarlo. Aunque la opción de minimización de la varianza según las correlaciones daba resultados similares en los backtests, estábamos más familiarizados con el funcionamiento y justificación teórica del método de Montecarlo, cubierto por el programa del máster [1]. Con este método, estamos aprovechando los grados de libertad que nos aporta la elección de los pesos de los activos en cartera para maximizar el ratio sharpe. Además, conseguimos mitigar, en cierto modo, la influencia que tiene el modelo de ML utilizado para la selección de activos en los retornos de la cartera.

2. Metodología aplicada

2.1. Modelos ML

Explicar lo que es un árbol de decisión, qué parámetros tiene, etc (citar apuntes de Manuel Rueda). A continuación, explicar los principales modelos de ML. Explicar con más detalle cómo funciona el gradient boosting y por qué es el modelo elegido para nuestra estrategia: hay razones cualitativas pero también porque probamos varios en un backtest y era el que mejor tiraba. También explicar cómo se entrena el modelo.

2.2. Desagregación de resultados

A la hora de calcular los resultados, es necesario realizar una desagregación de los resultados para realizar un análisis más completo del desempeño de la cartera. Esto cobra un especial sentido al tratarse de una estrategia de gestión cuantitativa, en la que las decisiones de inversión no se toman de manera directa. Como sabemos, los rebalanceos semanales de la cartera se realizan según un criterio puramente cuantitativo y complejo. Esta complejidad diluye la transparencia de la toma de decisiones, así que tratamos de analizar los movimientos en detalle para aprender sobre el modelo y sus puntos débiles.

La desagregación más sencilla y natural es el *performance attribution*, es decir, el detalle de la rentabilidad o P&L netos por cada activo en el que hemos estado invertidos. Su cálculo es inmediato: sería la rentabilidad compuesta de un activo en cada periodo, calculada a partir de los precios de compra-venta y el número de acciones en cartera en cada fecha de dicho activo. Todos estos datos han sido cuidadosa y metódicamente registrados en un csv con cada operación de compra-venta.

Aunque lo anterior nos da una visión del peso de cada activo elegido en el P&L final de la cartera, no aporta demasiada información sobre el desempeño del modelo de selección de activos. Este modelo trata de predecir los activos que van a realizar los mayores retornos en comparación con el resto de integrantes del índice, lo cual nos conduce a la pregunta: ¿acierta el modelo? Para ello, debemos fijarnos en los resultados semanales. En este punto, nos parece de interés mostrar, para cada semana, el puesto por rentabilidad que ha conseguido cada activo elegido (al inicio de la semana).

Lo comentado anteriormente nos habla de la capacidad de predicción del modelo, pero no sobre el efecto (en rentabilidad) que ha tenido la selección de activos. En este punto, nos vimos en la tesitura de elegir una métrica que refleje adecuadamente este efecto. Para ello, decidimos centrarnos en la métrica $\alpha = R_{\text{cartera}} - R_{\text{bm k}}$, ya que el objetivo de esta estrategia es batir al *benchmark*. Ahora, definimos las siguientes variables, utilizando el subíndice i para denotar el activo:

$$es_i = \omega_{bm k, i}(r_i - R_{bm k}), \quad ep_i = (\omega_{c, i} - \omega_{bm k, i})(r_i - R_{bm k}), \quad (1)$$

donde $\omega_{bm k, i}, \omega_{c, i}$ son los pesos del activo en el EuroStoxx50 y la cartera, respectivamente, $R_{bm k}$ es la rentabilidad semanal del índice y r_i es la rentabilidad bruta semanal del activo¹ (es decir, usando los precios de cierre y los dividendos, sin costes de operación).

La variable es_i se puede entender como un “efecto de selección”, ya que mide simplemente la rentabilidad del activo relativa al índice, ponderado por su peso en el mismo. Así, los activos tendrán un efecto de selección grande si superan sobradamente al *benchmark* y negativo si no lo hacen. Por otro lado, ep_i lo interpretamos como el efecto de los pesos elegidos para la cartera. La razón está en que esta métrica devuelve valores altos cuando un activo que supera al índice está sobreponderado con respecto al benchmark o un activo con rentabilidad inferior está infraponderado (y viceversa). Es

¹Es importante notar, en este punto, que en todo momento estamos utilizando rentabilidades simples no anualizadas. La elección de rentabilidades simples es importante para poder sumar las de los activos dentro de un mismo periodo, lo cual cumplirá propiedades deseables.

decir, es una especie de medida de cómo, elegidos unos activos, se asignan los pesos para maximizar la rentabilidad.

A partir de las definiciones, podemos comprobar fácilmente que

$$\begin{aligned}
es + ep &= \sum_i ES_i + \sum_i EP_i = \sum_i \omega_{bmk,i}(r_i - R_{bmk}) + \sum_i (\omega_{c,i} - \omega_{bmk,i})(r_i - R_{bmk}) \\
&= \sum_i \omega_{bmk,i} \cdot r_i - R_{bmk} + \sum_i \omega_{c,i} \cdot r_i - R_{bmk} - \sum_i \omega_{bmk,i} \cdot r_i + R_{bmk} \\
&= R_c^{\text{neta}} - R_{bmk},
\end{aligned} \tag{2}$$

donde hemos usado que la suma de los pesos verifica $\sum_i \omega_{bmk,i} = \sum_i \omega_{c,i} = 1$, y además la rentabilidad de la cartera es la suma de los productos de las rentabilidades y los pesos en la cartera $R_c^{\text{neta}} = \sum_i \omega_{c,i} \cdot r_i$. En consecuencia, si denotamos los costes operativos como ec , tenemos:

$$\begin{aligned}
\alpha &= R_{\text{cartera}} - R_{bmk} = ec + R_c^{\text{neta}} - R_{bmk} = ec + es + ep \\
&\Rightarrow R_{\text{cartera}} = R_{bmk} + ec + es + ep.
\end{aligned} \tag{3}$$

Recapitulando, hemos definido tres efectos (selección, peso y costes) de manera que somos capaces de desagregar la rentabilidad semanal de la cartera en la suma de estos efectos y la rentabilidad del benchmark, a la cual nos referiremos como “efecto de mercado”.

Hemos podido comprobar que estas métricas no solo permiten un análisis de la rentabilidad con detalle a nivel activo, sino que cada una de ellas tiene un sentido financiero perfectamente definido. Además, nuestra estrategia se puede dividir a muy grandes rasgos en dos partes: el modelo de machine learning realiza la selección de activos, mientras que los pesos se eligen en un proceso separado. Esta lógica nos permite separar las aportaciones de cada una de estas fases.

El razonamiento anterior ha sido exclusivamente centrado en el rendimiento en una sola semana, ya que los cálculos son más sencillos debido a que los pesos no varían en ese periodo. Sin embargo, también será necesario aplicar este análisis a todo el periodo de operación de la cartera. Esto es algo más complejo porque hay que componer los resultados de cada semana en un proceso iterativo.

Denotamos POS_k, BMK_k a los valores liquidativos al final de la k -ésima semana y $R_{c,k-1}, R_{bmk,k-1}$ sus rentabilidades simples durante esa semana² de nuestra cartera y una cartera que replica el índice, respectivamente. En este caso, estamos asumiendo que $POS_0 = BMK_0 = 10.000.000\text{€}$. De esta manera, para cada semana se verifica

$$POS_k = POS_{k-1}(1 + R_{c,k}), \quad BMK_k = BMK_{k-1}(1 + R_{bmk,k}). \tag{4}$$

Por otro lado, denotamos el alpha acumulado (en euros) durante la k -ésima semana como

$$A_k = POS_k - BMK_k = POS_{k-1}(1 + R_{c,k}) - BMK_{k-1}(1 + R_{bmk,k}). \tag{5}$$

Sumando y restando $BMK_{k-1}(1 + R_{c,k})$, llegamos a

$$A_k = (POS_{k-1} - BMK_{k-1})(1 + R_{c,k}) + BMK_{k-1}(R_{c,k} + R_{bmk,k}) = A_{k-1}(1 + R_{c,k}) + BMK_{k-1}\alpha_k. \tag{6}$$

Finalmente, como ya hemos visto que el alpha de un periodo se puede expresar como la suma de los efectos $\alpha_k = ec_k + es_k + ep_k$ (3), hemos llegado a una expresión recursiva:

$$A_k = A_{k-1}(1 + R_{c,k}) + BMK_{k-1}(EC_k + ES_k + EP_k) = EC_k^{ac} + ES_k^{ac} + EP_k^{ac}, \tag{7}$$

²Estamos considerando una semana como la unidad mínima de tiempo porque la estrategia tiene rebalanceos semanales, pero el razonamiento es válido para cualquier intervalo de tiempo.

donde $EC_k^{ac}, ES_k^{ac}, EP_k^{ac}$ son los efectos acumulados de costes, selección y pesos, respectivamente. Es importante notar que estos efectos acumulados no son rentabilidades como ec_k, ep_k, es_k , sino valores absolutos en euros. Se definen iterativamente como sigue:

$$\begin{aligned} EC_1^{ac} &= BMK_0 \cdot ec_k, & EC_k^{ac} &= EC_{k-1}^{ac}(1 + R_{c,k}) + BMK_{k-1} \cdot ec_k & \forall k \geq 2, \\ ES_1^{ac} &= BMK_0 \cdot es_k, & ES_k^{ac} &= ES_{k-1}^{ac}(1 + R_{c,k}) + BMK_{k-1} \cdot es_k & \forall k \geq 2, \\ EP_1^{ac} &= BMK_0 \cdot ep_k, & EP_k^{ac} &= EP_{k-1}^{ac}(1 + R_{c,k}) + BMK_{k-1} \cdot ep_k & \forall k \geq 2. \end{aligned} \quad (8)$$

En conclusión, hemos definido una desagregación en términos de los efectos de mercado, costes, selección de activos y elección de pesos. Este sistema funciona a nivel semanal y por activo, pero también se puede componer para obtener datos agregados del periodo completo.

3. Sistema e infraestructura del modelo

Ya hemos descrito en detalle la idea de la estrategia y su funcionamiento, pero sin entrar en la implementación técnica de la misma. En este respecto, hemos decidido programar la estrategia en Python debido a que se trata de un lenguaje de programación versátil y potente, pero también con el que estamos familiarizados todos los integrantes del grupo. En concreto, decidimos utilizar programación orientada a objetos definiendo varias clases modulares complementarias. Creemos que esta manera de trabajar es la idónea en este tipo de proyectos, ya que permite dividir el proyecto en módulos “independientes” y los miembros del grupo podemos trabajar paralelamente en clases diferentes del código para después compartir los avances mediante un repositorio de GitHub.

4. Resultados y análisis de la estrategia

5. Conclusiones

6. Anexo

6.1. Código

Referencias

- [1] Jose Javier Calderón. *Métodos Numéricos. Optimización*. 2026.
- [2] Jose María Contreras y Adrián González. *Gestión Cuantitativa*. 2026.